Pengembangan Sistem Prediksi Indikasi Kelainan Mata Berdasarkan Analisis Citra Mata

Lockdown

Disusun oleh:

Kevin Al Kautsar - 231110461

Winny Wijaya - 231110992

Michael Khosasi - 221111338



‘PROGRAM STUDI S-1 TEKNIK INFORMATIKA

FAKULTAS INFORMATIKA

UNIVERSITAS MIKROSKIL

MEDAN

2026

A. Problem

1. Latar Belakang dan Objek Penelitian

Gangguan penglihatan masih menjadi masalah kesehatan global. Laporan *World Report on Vision* menyebut sedikitnya 2,2 miliar orang di dunia mengalami gangguan penglihatan atau kebutaan, dan pada sedikitnya 1 miliar di antaranya gangguan tersebut sebenarnya dapat dicegah atau belum tertangani [1]. Katarak (*cataract*), glaukoma (*glaucoma*), dan retinopati diabetik (*diabetic retinopathy*) termasuk kelainan mata yang memerlukan deteksi dan penanganan dini. Pemeriksaannya banyak bergantung pada citra mata, sehingga analisis citra otomatis menarik dijadikan bahan eksperimen.

Pada citra fundus (foto retina), penelitian terdahulu telah memakai fitur yang dirancang manual dan klasifikator klasik. Acharya dkk. misalnya memakai *support vector machine* (SVM) pada fitur morfologi pembuluh darah, mikroaneurisma, eksudat, dan perdarahan untuk menentukan tahap retinopati diabetik pada 331 citra fundus [2]. Tinjauan Abràmoff dkk. merangkum teknik pencitraan dan analisis citra retina secara lebih luas [3].

Berangkat dari hal itu, kami membangun sistem prediksi indikasi kelainan mata dari citra dengan pendekatan *classical machine learning* tanpa *deep learning*. Setiap citra diubah menjadi 356 fitur numerik buatan sendiri (warna, ketajaman/tepi, tekstur, dan HOG), lalu diklasifikasikan ke empat kelas: cataract, diabetic_retinopathy, glaucoma, dan normal. Dua baseline (Dummy dan Logistic Regression), enam algoritma kandidat (SVM RBF, Extra Trees, LDA, QDA dengan PCA, Ridge Classifier, dan Passive-Aggressive), serta satu ensemble *hard voting* dibandingkan dengan Macro F1 sebagai metrik utama. Seluruh model dan evaluasi dijalankan dengan scikit-learn [4].

Dataset yang digunakan bercampur jenis citra: kelas cataract berupa foto mata bagian luar, sedangkan tiga kelas lainnya berupa citra fundus (Gambar 1). Perbedaan ini membuka peluang *shortcut learning*, yaitu model mengandalkan petunjuk yang tidak berkaitan dengan pola kelainan yang sebenarnya [5]. Karena itu skor empat kelas dan skor tiga kelas fundus dilaporkan terpisah, dan hasil eksperimen dibaca sebagai eksperimen akademik, bukan diagnosis atau rekomendasi klinis. Ringkasan proyek disajikan pada Tabel 1.

Tabel 1. Ringkasan proyek

Keterangan	Isi
Objek yang diklasifikasikan	Citra mata ke dalam empat kelas: cataract (katarak), diabetic_retinopathy (retinopati diabetik), glaucoma (glaukoma), dan normal
Dataset	Eye Disease Classification – Fundus Image Dataset (Kaggle, mahin661): 6.086 citra RGB 224×224 dengan pembagian bawaan train/val/test, lisensi CC BY 4.0. Tautan: https://www.kaggle.com/datasets/mahin661/eye-disease-classification-fundus-image-dataset [6]
Algoritma ML	Pendekatan classical machine learning. Baseline: Dummy dan Logistic Regression. Kandidat: SVM RBF [7], Extra Trees, LDA, QDA (+PCA), Ridge Classifier, Passive-Aggressive. Ensemble: hard voting [8]. Model terpilih sementara: SVM RBF (C = 10,0)
Target	Label kelas dari nama folder dataset (4 kelas); klasifikasi multi-kelas
Metrik	Macro F1 (utama); Balanced Accuracy dan Accuracy (pendukung)
Referensi paper utama	Fitur manual dan SVM pada citra fundus: [2]. Tinjauan analisis citra retina: [3]. Fitur HOG: [9]. Tekstur LBP dan GLCM: [10], [11]. Shortcut learning: [5]

2. Rumusan Masalah

1. Bagaimana mengubah citra mata (citra fundus dan foto mata bagian luar) menjadi fitur numerik yang dapat digunakan dalam klasifikasi dengan classical machine learning?
2. Bagaimana kinerja baseline (Dummy dan Logistic Regression) dibandingkan enam algoritma kandidat dan satu ensemble hard voting pada empat kelas, dan model mana yang dipilih berdasarkan validation?
3. Seberapa stabil kinerja model pada Stratified 5-Fold cross-validation, dan apakah hasil di validation bertahan pada data test?
4. Kelas dan kelompok fitur mana yang paling berpengaruh pada hasil prediksi, kelas mana yang paling sulit diklasifikasikan, dan apakah kelas cataract menggelembungkan skor karena perbedaan jenis citra?

3. Tujuan

1. Membangun alur dari citra menjadi 356 fitur numerik (warna, ketajaman/tepi, tekstur, dan HOG) tanpa deep learning.
2. Membandingkan baseline, enam algoritma kandidat, dan satu ensemble dengan Macro F1 sebagai metrik utama, serta memilih model hanya berdasarkan validation.
3. Mengevaluasi kestabilan model dengan Stratified 5-Fold cross-validation pada data latih dan melaporkan hasil test satu kali setelah model dipilih.
4. Mendiagnosis kesalahan model (kinerja per kelas, pasangan kesalahan, kelompok fitur, pengaruh aug_noise, dan skor empat kelas versus tiga kelas) serta menjelaskan keterbatasan, termasuk risiko kebocoran data dan shortcut learning.

4. Target, Fitur, dan Jenis Masalah

Target : label kelas yang diperoleh dari nama folder dataset, yaitu cataract, diabetic_retinopathy, glaucoma, dan normal. Unit observasi adalah satu file citra. Label tidak diverifikasi secara independen oleh tenaga medis.

Fitur : 356 fitur numerik yang diekstraksi dari tiap citra, terdiri atas 12 fitur warna (rata-rata dan simpangan baku kanal RGB dan HSV), 6 fitur ketajaman/tepi, 14 fitur tekstur (histogram LBP dan properti GLCM), dan 324 fitur HOG dari citra grayscale 64×64.

Jenis masalah : supervised learning dengan klasifikasi multi-kelas pada data tabular hasil ekstraksi fitur dari citra.

Lingkup klaim : kelas cataract berupa foto mata bagian luar, sedangkan tiga kelas lain berupa citra fundus (Gambar 1). Model dapat memisahkan cataract hanya dari jenis citranya (F1 cataract 1,000 pada validation dan test), sehingga skor empat kelas tidak boleh dibaca sebagai kemampuan mendeteksi penyakit. Kemampuan membedakan tiga kelas fundus yang lebih representatif berada pada kisaran Macro F1 0,79 sampai 0,80 di validation (Bagian I). Laporan ini tidak mengklaim bahwa sistem dapat dipakai untuk diagnosis.

B. Dataset

Kami memakai data sekunder berjudul Eye Disease Classification – Fundus Image Dataset yang diunggah oleh mahin661 di Kaggle [6]. Dataset berisi citra empat kelas dengan pembagian bawaan train, val, dan test; kelas dan split dibaca dari struktur folder (split/label/file citra). Dataset tidak menyediakan tabel fitur, sehingga seluruh fitur numerik dibuat sendiri pada Bagian C. Ringkasan data disajikan pada Tabel 2.

Tabel 2. Ringkasan dataset

Keterangan	Isi
Sumber	Kaggle, mahin661, Eye Disease Classification – Fundus Image Dataset [6]. https://www.kaggle.com/datasets/mahin661/eye-disease-classification-fundus-image-dataset
Lisensi	CC BY 4.0
Jumlah data	6.086 file citra (train 5.200; val 440; test 446)
Kelas	cataract, diabetic_retinopathy, glaucoma, normal
Format citra	RGB, 224×224 piksel; JPEG 6.078 file dan PNG 8 file
Label	Dari nama folder; tidak diverifikasi secara independen oleh tenaga medis
Data augmentasi	1.847 file berawalan aug_, termasuk 276 file aug_noise_* yang seluruhnya berada di train
Sebaran kelas	Train seimbang (1.300 citra per kelas). Val dan test tidak seimbang: cataract ±12%, diabetic_retinopathy ±34%, glaucoma ±30%, normal ±23%

1. Kualitas Data

Pemeriksaan kualitas dilakukan pada tingkat file citra dan metadata yang dibentuk dari struktur folder; hasilnya dirangkum pada Tabel 3. Secara teknis berkas dataset bersih: tidak ada nilai kosong dan tidak ada file rusak. Masalah utama justru terdapat pada label. Dari 128 grup file identik (hash MD5), 125 grup berisi gambar yang sama dengan label berbeda, yang mengindikasikan adanya label noise pada dataset sumber. Selain itu terdapat 3 grup identik yang muncul lintas split dan 61 citra train yang hampir identik dengan citra val atau test (45 di antaranya berlabel berbeda), sehingga berpotensi menimbulkan kebocoran data [12]. Seluruhnya ditangani pada Bagian C, tetapi kualitas label tetap membatasi performa yang realistis.

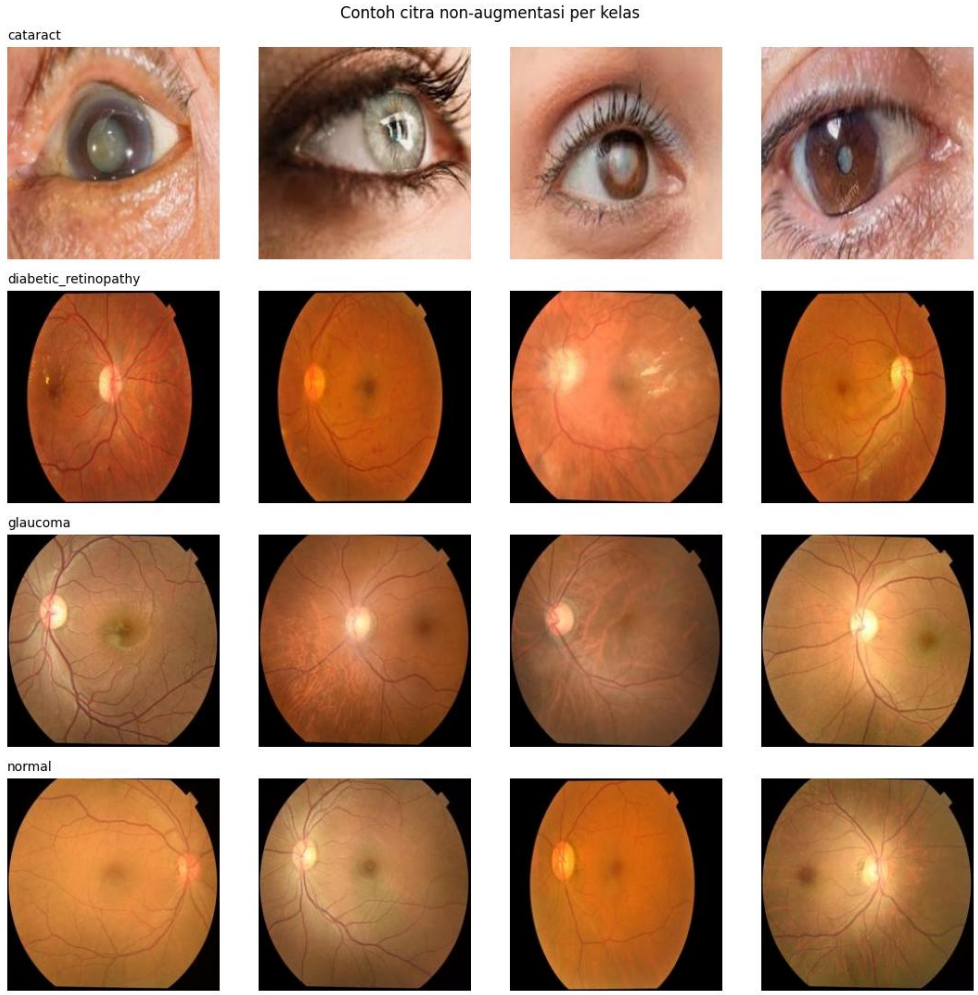
Tabel 3. Hasil pemeriksaan kualitas data

Pemeriksaan	Hasil
Jumlah file citra	6.086 (train 5.200; val 440; test 446)
Nilai kosong pada seluruh kolom metadata	0
File tidak terbaca	0
Dimensi dan mode warna	224×224 piksel, RGB (seragam)
File bernama aug_*	1.847 (276 di antaranya aug_noise_*, seluruhnya di train)
Grup file identik (MD5)	128 grup; 125 grup berlabel konflik; 3 grup muncul lintas split
Near-duplicate train terhadap val/test (dHash dan SSIM)	61 citra train (45 berlabel berbeda dari pasangannya)
Kesimpulan kualitas data	**Berkas bersih secara teknis, tetapi label sumber mengandung noise (125 dari 128 grup identik berlabel konflik) dan ada duplikasi lintas split yang harus ditangani sebelum pemodelan.**

Distribusi kelas berbeda antar-split: train seimbang, sedangkan val dan test timpang. Pada validation, Dummy yang selalu menebak kelas mayoritas memperoleh Accuracy 0,3432 tetapi Macro F1 hanya 0,1278, sehingga Accuracy saja tidak mencerminkan kinerja per kelas [13]. Karena itu Macro F1 dan Balanced Accuracy dijadikan metrik utama.

2. Exploratory Data Analysis (EDA)

EDA dilakukan untuk melihat contoh citra tiap kelas, merangkum karakteristik visual dengan statistik deskriptif, dan mengaudit citra aug_noise_*. Contoh citra ditunjukkan pada Gambar 1, dan statistik deskriptor citra pada Tabel 4.



Gambar 1. Contoh citra non-augmentasi tiap kelas (empat contoh per kelas; dari atas ke bawah: cataract, diabetic_retinopathy, glaucoma, normal)

Tabel 4. Statistik deskriptor citra per kelas (seluruh 6.086 citra sebelum preprocessing)

Kelas	Jumlah citra	Median black_ratio	Median brightness	Median lap_var	Rata-rata lap_var
cataract	1.409	0,000	131,434	143,169	4.304,651
diabetic_retinopathy	1.602	0,157	95,927	197,535	563,421
glaucoma	1.570	0,157	99,635	211,898	1.157,145
normal	1.505	0,156	111,308	239,481	2.259,857

Statistik pada Tabel 4 bersifat deskriptif, bukan uji signifikansi maupun diagnosis klinis. black_ratio adalah proporsi piksel grayscale dengan intensitas di bawah 10, brightness adalah rata-rata intensitas grayscale, dan lap_var adalah varians respons Laplacian. Temuan EDA:

1. **Cataract berasal dari jenis citra yang berbeda.** Gambar 1 menunjukkan cataract berupa foto mata bagian luar, sedangkan diabetic_retinopathy, glaucoma, dan normal berupa citra fundus dengan latar hitam di tepi. Tabel 4 mendukung hal ini: median black_ratio cataract 0,000 dibanding 0,156 sampai 0,157 pada kelas lain, dan median brightness 131,4 dibanding 95,9 sampai 111,3. Cataract mudah dipisahkan karena jenis citranya, bukan pola penyakitnya (risiko *shortcut learning* [5]).
2. **Tiga kelas fundus mirip pada deskriptor sederhana** (black_ratio dan brightness), sehingga dibutuhkan fitur yang lebih kaya seperti HOG dan tekstur.
3. **lap_var sangat miring ke kanan** (cataract: rata-rata 4.304,7 dibanding median 143,2), sehingga rata-rata dan simpangan baku kurang representatif. Transformasi (misalnya logaritma) direncanakan pada tahap berikutnya.
4. **Citra aug_noise_* memang ber-noise kuat.** Dengan ambang persentil ke-95 lap_var pada train (22.271,183), seluruh 260 citra di atas ambang adalah aug_noise_*, dan 0 dari 5.810 file lain melewati ambang itu. Sebanyak 144 dari 276 file aug_noise_* berlabel cataract; sisanya diabetic_retinopathy (15), glaucoma (37), dan normal (80). Penanda ini bersifat statistik dan bukan bukti bahwa suatu citra pasti ber-noise; pengaruhnya diuji secara empiris pada Bagian E dan I.

C. Preprocessing

1. Langkah Preprocessing dan Alasannya

Tahapan preprocessing beserta alasannya disajikan pada Tabel 5.

Tabel 5. Langkah preprocessing dan alasannya

No	Langkah	Alasan
1	Indeks citra dari struktur folder; label dari nama folder, split bawaan dipertahankan	Mempertahankan pembagian dari sumber data
2	Audit keterbacaan, dimensi, dan mode warna (0 file rusak)	Memastikan semua citra dapat diproses
3	Deduplikasi identik (MD5): grup berlabel konflik dikeluarkan seluruhnya; pada grup berlabel sama satu salinan dipertahankan dengan prioritas test, lalu val, lalu train	Mencegah konflik label dan salinan identik lintas split
4	Audit near-duplicate: kandidat dari dHash 256-bit pada 8 orientasi (jarak Hamming ≤ 1), dikonfirmasi SSIM ≥ 0,98; salinan train yang cocok dengan val/test dikeluarkan dari train	Mengurangi kebocoran akibat citra hampir sama
5	Citra aug_noise_* dipertahankan di train; dampaknya diuji dengan dua skenario data latih (dengan dan tanpa aug_noise_*)	Tidak menghapus data hanya berdasarkan dugaan visual atau statistik
6	Ekstraksi 356 fitur numerik per citra	Model klasik membutuhkan masukan tabular
7	StandardScaler (dan PCA untuk QDA) ditempatkan di dalam Pipeline	Statistik transformasi hanya dipelajari dari data latih/fold sehingga tidak terjadi kebocoran

2. Audit Duplikasi dan Kebocoran Data

Audit dilakukan dalam dua tahap. Tahap pertama memakai hash MD5 untuk menemukan file identik. Grup file identik yang labelnya berkonflik dikeluarkan seluruhnya (250 citra dari 125 grup) karena label yang benar tidak dapat ditentukan. Pada grup yang labelnya sama, satu salinan dipertahankan dengan prioritas test, lalu validation, kemudian train (3 salinan tambahan dikeluarkan). Tahap kedua mencari near-duplicate lintas split: dHash 256-bit pada 8 orientasi (citra asli dan cermin, rotasi 0°, 90°, 180°, 270°) menyaring kandidat dengan jarak Hamming paling banyak 1, lalu kandidat dikonfirmasi dengan SSIM minimal 0,98 [14]. Dari 69 kandidat, 61 terkonfirmasi (45 berlabel berbeda) dan seluruhnya dikeluarkan dari train. Tidak ditemukan pasangan near-duplicate antara val dan test. Perubahan jumlah citra pada tiap tahap ditunjukkan pada Tabel 6.

Tabel 6. Jumlah citra per tahap preprocessing dan split

Tahap	Train	Val	Test	Total
Data awal	5.200	440	446	6.086
Setelah file tidak terbaca dikeluarkan	5.200	440	446	6.086
Setelah deduplikasi MD5	4.953	437	443	5.833
Setelah audit near-duplicate	**4.892**	**437**	**443**	**5.772**

Transparansi penggunaan test. Isi file test tidak diubah dan tidak ada file test yang dikeluarkan pada tahap near-duplicate, tetapi hash dan kemiripan citra test dipakai dalam audit lintas split untuk menentukan salinan train yang dikeluarkan. Jumlah citra test juga berkurang dari 446 menjadi 443 pada tahap MD5. Karena itu test bukan *blind test* pada tahap kurasi. Keterbatasan ini kami laporkan, dan pada tahap berikutnya split akan dibentuk ulang berdasarkan grup sumber, pasien, atau keluarga augmentasi.

3. Pembagian Data

Split bawaan dataset (train, val, test) dipertahankan setelah audit duplikasi. Train dipakai untuk melatih model dan untuk cross-validation, validation untuk memilih konfigurasi dan model, sedangkan test hanya dipakai satu kali pada evaluasi akhir (Bagian H). Distribusi kelas pada tiap bagian ditunjukkan pada Tabel 7. Split ini belum berbasis pasien atau sumber citra, sehingga citra asli dan turunan augmentasinya dapat berada pada fold yang berbeda.

Tabel 7. Distribusi kelas setelah preprocessing

Kelas	Train	Train tanpa aug_noise_*	Validation	Test
cataract	1.290 (26,4%)	1.146 (24,8%)	54 (12,4%)	55 (12,4%)
diabetic_retinopathy	1.292 (26,4%)	1.277 (27,7%)	150 (34,3%)	151 (34,1%)
glaucoma	1.151 (23,5%)	1.114 (24,1%)	132 (30,2%)	135 (30,5%)
normal	1.159 (23,7%)	1.079 (23,4%)	101 (23,1%)	102 (23,0%)
Total	**4.892**	**4.616**	**437**	**443**

4. Feature Engineering

Setiap citra diubah menjadi 356 fitur numerik dalam empat kelompok (Tabel 8). Statistik warna dan tekstur dihitung pada area non-latar (piksel grayscale lebih dari 15) agar latar hitam pada

citra fundus tidak mendominasi. Ekstraksi memakai scikit-image [15] dan OpenCV. Matriks fitur akhir berukuran 5.772 × 356 dan tidak mengandung nilai kosong maupun tak hingga.

Tabel 8. Kelompok fitur

Kelompok	Jumlah	Isi fitur
Warna	12	Rata-rata dan simpangan baku kanal R, G, B, H, S, dan V
Ketajaman/tepi	6	Varians Laplacian (lap_var), kepadatan tepi Canny, rata-rata dan simpangan baku kanal hijau setelah CLAHE, rasio piksel gelap, dan rasio piksel terang
Tekstur	14	Histogram LBP uniform 10 bin (P = 8, R = 1) [10] dan empat properti GLCM (contrast, homogeneity, energy, correlation) [11] pada 50% area tengah (112×112 piksel, 32 level keabuan, jarak 1 dan 3, sudut 0° dan 90°)
HOG	324	Histogram of Oriented Gradients [9]: 9 orientasi, sel 16×16 piksel, blok 2×2, pada citra grayscale 64×64
Total	**356**	

Pada data train, 21 dari 496 pasangan fitur non-HOG memiliki korelasi absolut di atas 0,90 (misalnya r_mean dan v_mean 0,995; lap_var dan glcm_contrast 0,990). Fitur tidak dibuang pada tahap ini agar tidak ada seleksi di luar cross-validation; redundansi ini dievaluasi pada tahap berikutnya.

Untuk memutuskan apakah seluruh fitur diperlukan, enam set fitur dibandingkan dengan SVM RBF (C = 1,0) memakai Stratified 5-Fold CV pada data train saja (Tabel 9). Aturan yang ditetapkan sebelumnya: subset alternatif dipakai hanya bila unggul lebih dari 0,01 CV Macro F1 terhadap seluruh fitur. Tidak ada subset yang memenuhi aturan itu (seluruh fitur justru tertinggi dengan 0,8206), sehingga 356 fitur dipertahankan. Skor pada Tabel 9 tidak boleh dibaca sebagai estimasi final yang bebas bias karena dipakai untuk memutuskan set fitur.

Tabel 9. Perbandingan set fitur (SVM RBF, 5-fold CV pada train)

Set fitur	Jumlah fitur	CV Macro F1 (rata-rata ± std)	CV Balanced Acc	CV Accuracy
Warna	12	0,6987 ± 0,0159	0,7045	0,7138
Ketajaman	6	0,6404 ± 0,0110	0,6499	0,6596
Tekstur	14	0,7194 ± 0,0105	0,7279	0,7359
HOG	324	0,7948 ± 0,0193	0,7960	0,8013
Non-HOG	32	0,7969 ± 0,0160	0,7989	0,8062
Semua fitur (dipilih)	**356**	**0,8206 ± 0,0154**	**0,8219**	**0,8275**

D. Baseline

1. Baseline yang Digunakan

Dua baseline dipakai sebagai pembanding awal (Tabel 10). Keduanya memakai 356 fitur yang sama dengan model lain dan dihitung pada validation terlebih dahulu; nilai test baru dihitung pada Bagian H setelah model final dipilih.

Tabel 10. Baseline pembanding

Baseline	Fungsi
Dummy (kelas mayoritas)	Tidak belajar dari fitur dan selalu memprediksi kelas terbanyak. Menjadi batas bawah yang harus dilampaui model apa pun.
Logistic Regression (StandardScaler, C = 1,0, class_weight = balanced)	Model linear sederhana yang menjadi tolok ukur apakah model yang lebih kompleks benar-benar memberi peningkatan berarti. Dilatih dua kali (dengan dan tanpa aug_noise_*) agar dapat dibandingkan dengan model final yang dilatih tanpa aug_noise_*.

2. Hasil Baseline

Hasil kedua baseline pada validation dan pada 5-fold cross-validation data latih ditunjukkan pada Tabel 11.

Tabel 11. Hasil baseline (validation dan 5-fold CV pada data latih)

Model	Data latih	Val Accuracy	Val Balanced Acc	Val Macro F1	CV Macro F1 (rata-rata ± std)
Dummy	Dengan aug_noise_*	0,3432	0,2500	0,1278	0,1045 ± 0,0001
Logistic Regression	Dengan aug_noise_*	0,8124	0,8374	0,8352	0,8212 ± 0,0130
Logistic Regression	Tanpa aug_noise_*	0,8124	0,8374	0,8353	0,8299 ± 0,0211

3. Analisis Awal Baseline

Dummy hanya mencapai Macro F1 0,1278 dengan Balanced Accuracy 0,2500 (setara tebakan acak untuk empat kelas), meskipun Accuracy-nya 0,3432 karena diabetic_retinopathy adalah kelas terbanyak di validation. Logistic Regression menaikkan Macro F1 menjadi 0,8353, sehingga fitur yang dibuat jelas mengandung informasi yang dapat dipelajari. Penambahan aug_noise_* tidak mengubah hasil Logistic Regression di validation (0,8352 dibanding 0,8353). Angka 0,8353 inilah yang harus dilampaui model final secara bermakna.

E. Kandidat Model dan Strategi Pemilihan

1. Kandidat Model Awal

Selain baseline, enam algoritma kandidat yang mewakili karakteristik berbeda diuji (Tabel 12). StandardScaler dan PCA berada di dalam Pipeline sehingga hanya belajar dari data latih atau fold terkait. Bobot kelas diseimbangkan (class_weight = balanced) pada SVM, Extra Trees, Ridge Classifier, dan Passive-Aggressive, sedangkan LDA dan QDA memakai prior seragam. Setiap algoritma diuji pada grid hyperparameter kecil dan dua skenario data latih (dengan dan tanpa aug_noise_*), sehingga total 32 konfigurasi dievaluasi pada validation. Karena banyak

konfigurasi dibandingkan pada validation yang sama, skor validation bersifat selektif dan dapat optimistik.

Tabel 12. Algoritma kandidat dan grid hyperparameter

Model	Alasan pemilihan	Grid hyperparameter
SVM RBF [7]	Batas keputusan non-linear pada fitur numerik yang distandardisasi	C ∈ {1; 10; 100}
Extra Trees	Ensemble pohon acak (300 pohon); mampu memodelkan hubungan non-linear dan tidak memerlukan scaling	max_features ∈ {sqrt; 0,3}
LDA (shrinkage)	Model linear dengan regularisasi kovarians	shrinkage ∈ {auto; 0,2}
QDA (+PCA)	Batas keputusan kuadratik; PCA 32 komponen mengurangi dimensi sebelum estimasi kovarians	reg_param ∈ {0,1; 0,5; 0,8}
Ridge Classifier	Model linear dengan regularisasi L2	alpha ∈ {0,1; 10; 100}
Passive-Aggressive	Model linear berbasis margin; disertakan sebagai kandidat konvensional	C ∈ {0,001; 0,01; 0,1}

2. Hasil Perbandingan Awal

Konfigurasi terbaik tiap algoritma berdasarkan Macro F1 validation ditunjukkan pada Tabel 13. Seluruh konfigurasi terbaik berasal dari skenario tanpa aug_noise_* (4.616 citra latih). SVM RBF dengan C = 10,0 tertinggi (Macro F1 0,8475), disusul Passive-Aggressive (0,8243) dan Extra Trees (0,8218), sedangkan QDA terendah (0,7570).

Tabel 13. Konfigurasi terbaik tiap algoritma (data latih tanpa aug_noise_*)

Model	Konfigurasi	Val Accuracy	Val Balanced Acc	Val Macro F1	CV Macro F1 (rata-rata ± std)
SVM RBF	C = 10,0	0,8284	0,8495	0,8475	0,8497 ± 0,0206
Passive-Aggressive	C = 0,01	0,8009	0,8249	0,8243	0,7946 ± 0,0107
Extra Trees	max_features = 0,3	0,8032	0,8276	0,8218	0,8292 ± 0,0087
LDA	shrinkage = auto	0,7918	0,8209	0,8188	0,8159 ± 0,0189
Ridge Classifier	alpha = 100,0	0,7872	0,8184	0,8140	0,8160 ± 0,0187
QDA (+PCA)	reg_param = 0,5	0,7162	0,7603	0,7570	0,7552 ± 0,0082

3. Kriteria Keputusan

1. Model dipilih hanya berdasarkan Macro F1 validation; Balanced Accuracy menjadi pemecah seri.
2. Test tidak dipakai untuk memilih fitur, hyperparameter, maupun model.
3. Selisih Macro F1 yang lebih kecil daripada simpangan baku cross-validation tidak dianggap sebagai keunggulan yang kuat.
4. Bila dua model setara, model yang lebih sederhana diutamakan.

4. Keputusan Model

Berdasarkan kriteria tersebut, SVM RBF (C = 10,0, dilatih tanpa aug_noise_*) dipilih sebagai model final sementara karena Macro F1 validation tertinggi (0,8475) dengan CV 0,8497 ± 0,0206. Keputusan ini belum dikunci: keunggulan SVM atas Logistic Regression di validation

hanya 0,0122 dan lebih kecil daripada simpangan baku CV, dan pada test hasilnya berbalik (Bagian H). Skenario tanpa aug_noise_* dipilih karena lebih baik pada 6 dari 6 keluarga model di validation, tetapi selisihnya kecil (0,004 sampai 0,014) dan hanya berasal dari satu split validation (Tabel 21).

F. Strategi Evaluasi dan Stabilitas Validasi

Strategi evaluasi yang dipakai pada seluruh bagian disajikan pada Tabel 14.

Tabel 14. Strategi evaluasi

Aspek	Keputusan	Alasan
Pembagian data	Split bawaan train/val/test setelah audit duplikasi	Mempertahankan pembagian sumber sambil mengurangi salinan lintas split
Pemilihan fitur awal	Stratified 5-Fold CV pada train (Bagian C.4)	Validation tidak dipakai untuk memilih subset fitur
Pemilihan konfigurasi dan model	Hold-out validation dengan Macro F1 sebagai metrik utama	Memberi perhatian setara pada tiap kelas
Uji kestabilan	Stratified 5-Fold CV (shuffle, random_state = 42) pada train untuk baseline dan kandidat terpilih [16]	Menunjukkan variasi antar-fold
Evaluasi akhir	Test dipakai satu kali pada Bagian H setelah model dipilih dari validation	Test tidak dipakai untuk memilih hyperparameter atau model
Metrik	Macro F1 (utama); Balanced Accuracy, Accuracy, serta precision, recall, dan F1 per kelas (pendukung)	Kelas pada val dan test tidak seimbang [13]
Pencegahan leakage	Audit MD5 dan dHash+SSIM; scaling dan PCA di dalam Pipeline	Transformasi hanya dipelajari dari data latih atau fold

Satu kali cross-validation dapat kebetulan bagus atau buruk, sehingga kestabilan dinilai dari simpangan baku Macro F1 antar-fold. Hasil 5-fold CV pada data latih untuk baseline dan konfigurasi kandidat terpilih ditunjukkan pada Tabel 15.

Tabel 15. Stabilitas 5-fold CV pada data latih (Stratified, random_state = 42)

Tahap	Model (konfigurasi)	Data latih	CV Macro F1 (rata-rata ± std)	CV Balanced Acc	CV Accuracy
Baseline	Dummy	Dengan aug	0,1045 ± 0,0001	0,2500	0,2641
Baseline	Logistic Regression (C = 1,0)	Dengan aug	0,8212 ± 0,0130	0,8214	0,8264
Baseline	Logistic Regression (C = 1,0)	Tanpa aug	0,8299 ± 0,0211	0,8301	0,8321
Kandidat	SVM RBF (C = 10,0)	Tanpa aug	0,8497 ± 0,0206	0,8501	0,8520
Kandidat	Passive-Aggressive (C = 0,01)	Tanpa aug	0,7946 ± 0,0107	0,7949	0,7979
Kandidat	Extra Trees (max_features = 0,3)	Tanpa aug	0,8292 ± 0,0087	0,8309	0,8349
Kandidat	LDA (shrinkage = auto)	Tanpa aug	0,8159 ± 0,0189	0,8168	0,8187
Kandidat	Ridge Classifier (alpha = 100,0)	Tanpa aug	0,8160 ± 0,0187	0,8178	0,8204
Kandidat	QDA (reg_param = 0,5)	Tanpa aug	0,7552 ± 0,0082	0,7573	0,7574

Apakah performa model stabil ketika pembagian data berubah? Cukup stabil. Simpangan baku Macro F1 antar-fold berkisar 0,0082 sampai 0,0211 pada semua model selain Dummy. Variasi terbesar terdapat pada Logistic Regression tanpa aug_noise_* (0,0211) dan SVM RBF

(0,0206), sedangkan Extra Trees (0,0087) dan QDA (0,0082) paling stabil, walaupun QDA memiliki rata-rata terendah (0,7552). Selisih rata-rata CV antara SVM dan Logistic Regression tanpa aug_noise_* hanya 0,0198 (0,8497 dibanding 0,8299), lebih kecil daripada simpangan baku keduanya, sehingga urutan kedua model dapat berganti antar pembagian data.

CV pada Tabel 15 dihitung untuk konfigurasi yang sudah dipilih di validation, sehingga hanya menjadi indikator kestabilan relatif, bukan nested cross-validation dan bukan estimasi yang bebas bias seleksi. Split acak juga belum memisahkan pasien atau sumber citra, sehingga angka CV dapat optimistik.

G. Ensemble: Perbandingan dengan Model Awal

Ensemble yang diuji pada Milestone 1 adalah *hard voting* [8]. Tiga keluarga model dengan Macro F1 validation tertinggi pada skenario data latih yang sama (tanpa aug_noise_*) dipilih sebagai anggota, yaitu SVM RBF (C = 10,0), Passive-Aggressive (C = 0,01), dan Extra Trees (max_features = 0,3). Tiap anggota memberi satu suara kelas dan prediksi akhir adalah kelas dengan suara terbanyak. Model awal sebagai pembanding adalah SVM RBF; Logistic Regression ditampilkan sebagai tolok ukur. Hasilnya ditunjukkan pada Tabel 16.

Tabel 16. Perbandingan ensemble dengan model awal (data latih tanpa aug_noise_*)

Model	Val Macro F1	Val Balanced Acc	Val Accuracy	CV Macro F1 (rata-rata ± std)
SVM RBF (C = 10,0), model awal	0,8475	0,8495	0,8284	0,8497 ± 0,0206
Hard Voting (SVM RBF, Passive-Aggressive, Extra Trees)	0,8474	0,8494	0,8284	0,8534 ± 0,0157
Logistic Regression (pembanding)	0,8353	0,8374	0,8124	0,8299 ± 0,0211

Macro F1 validation hard voting (0,8474) praktis sama dengan SVM (0,8475; selisih -0,0001) dengan Accuracy yang identik (0,8284). Pada CV, hard voting (0,8534 ± 0,0157) unggul 0,0037 atas SVM (0,8497 ± 0,0206), selisih yang jauh lebih kecil daripada simpangan baku SVM. Dengan demikian eksperimen ini belum menunjukkan bahwa ensemble meningkatkan kinerja dibandingkan model tunggal. Karena anggota ensemble dipilih berdasarkan validation, skor ensemble juga bersifat selektif. SVM tetap dipilih karena aturan yang ditetapkan sebelumnya (Macro F1 validation tertinggi) dan modelnya lebih sederhana; hard voting dibawa ke tahap berikutnya bersama soft voting, bagging, dan stacking. Metrik test tidak dihitung untuk ensemble agar test tidak ikut dipakai dalam pemilihan.

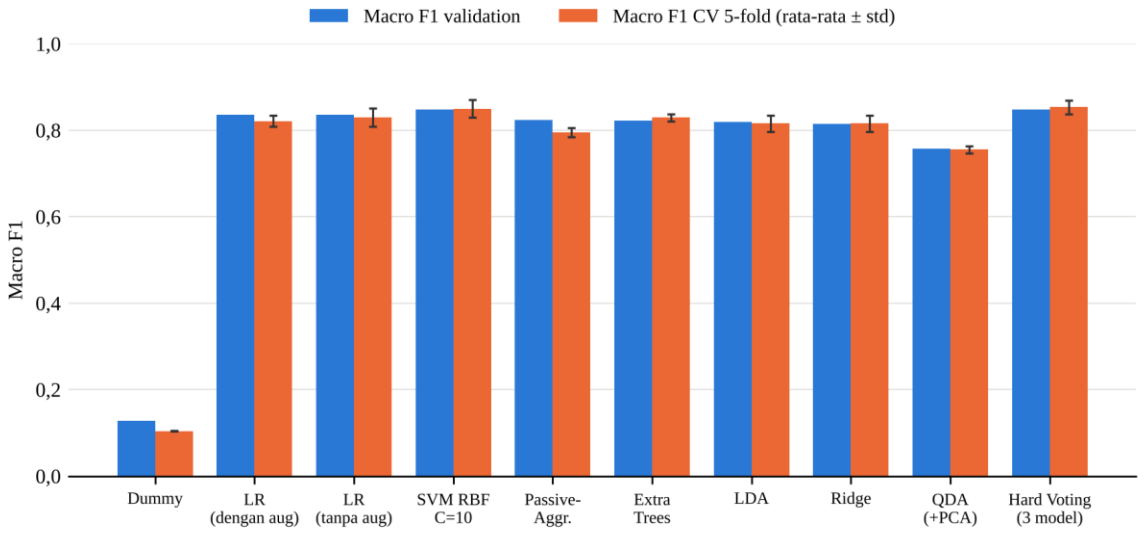
H. Hasil Eksperimen Awal

Model final dipilih hanya berdasarkan Macro F1 validation, yaitu SVM RBF (C = 10,0, tanpa aug_noise_*). Setelah keputusan dibuat, test dihitung satu kali untuk model final dan dua baseline pembanding (Tabel 17); kandidat lain tidak dievaluasi pada test (tanda "-"). Gambar

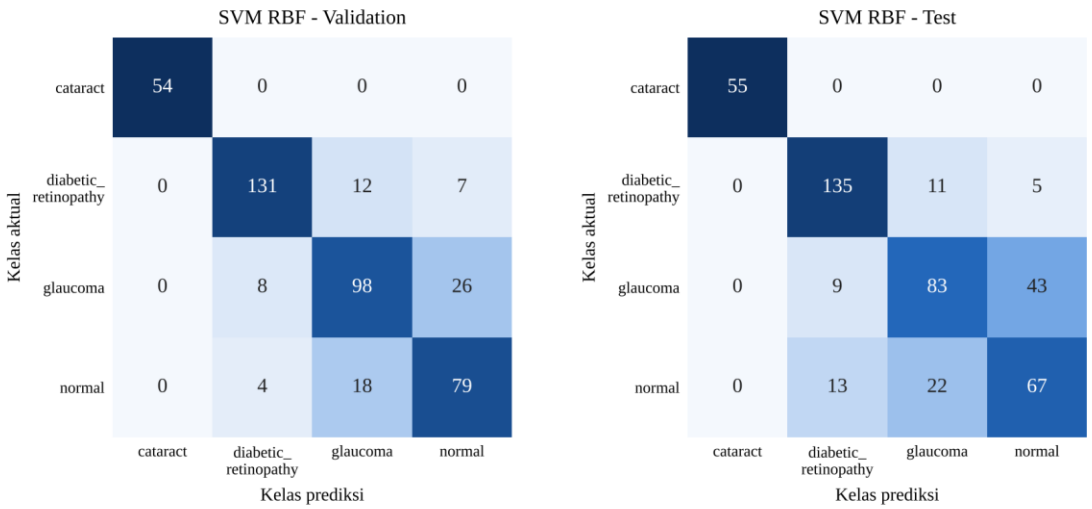
2 membandingkan seluruh model pada validation dan CV, dan Gambar 3 menunjukkan confusion matrix model final.

Tabel 17. Hasil seluruh model pada validation, CV, dan test

Model	Data latih	Val Macro F1	CV Macro F1	Test Macro F1	Test Bal. Acc	Test Accuracy
Dummy	Dengan aug	0,1278	0,1045	0,1271	0,2500	0,3409
Logistic Regression (C = 1,0)	Dengan aug	0,8352	0,8212	0,8204	0,8217	0,7991
Logistic Regression (C = 1,0)	Tanpa aug	0,8353	0,8299	0,8154	0,8172	0,7923
SVM RBF (C = 10,0), model final	**Tanpa aug**	**0,8475**	**0,8497**	**0,7889**	**0,7914**	**0,7675**
Passive-Aggressive (C = 0,01)	Tanpa aug	0,8243	0,7946	-	-	-
Extra Trees (max_features = 0,3)	Tanpa aug	0,8218	0,8292	-	-	-
LDA (shrinkage = auto)	Tanpa aug	0,8188	0,8159	-	-	-
Ridge Classifier (alpha = 100,0)	Tanpa aug	0,8140	0,8160	-	-	-
QDA (reg_param = 0,5)	Tanpa aug	0,7570	0,7552	-	-	-
Hard Voting (3 model)	Tanpa aug	0,8474	0,8534	-	-	-



Gambar 2. Perbandingan Macro F1 validation dan CV 5-fold (rata-rata ± std) untuk baseline, kandidat, dan ensemble



Gambar 3. Confusion matrix SVM RBF pada validation (kiri) dan test (kanan); angka adalah jumlah citra dan intensitas warna menunjukkan proporsi dalam kelas aktual

Hasil test mengubah kesimpulan yang diperoleh dari validation:

1. **Model final belum terbukti lebih baik dari baseline.** Dengan data latih yang sama, SVM RBF unggul tipis atas Logistic Regression di validation (Macro F1 0,8475 dibanding 0,8353; selisih +0,0122), tetapi di test justru lebih rendah (0,7889 dibanding 0,8154; selisih -0,0265). Selisih di validation lebih kecil daripada simpangan baku CV SVM (0,0206) dan Logistic Regression (0,0211), dan validation dipakai untuk memilih dari 32 konfigurasi sehingga cenderung optimistik.
2. **Skor SVM turun dari validation ke test** (0,8475 menjadi 0,7889; turun 0,0586), lebih besar daripada penurunan Logistic Regression (0,8353 menjadi 0,8154; turun 0,0199). Hal ini sejalan dengan skor validation yang selektif. Test hanya berisi 443 citra pada satu split, sehingga angka ini juga memiliki ketidakpastian.
3. **Semua model jauh di atas batas bawah.** Dummy hanya mencapai Macro F1 0,1271 pada test, sedangkan Logistic Regression dan SVM berada pada 0,79 sampai 0,82.
4. **Keputusan:** SVM tetap menjadi kandidat utama tetapi belum dikunci. Tahap berikutnya membandingkannya lagi dengan Logistic Regression yang dituning dan dengan group cross-validation.

I. Diagnosis Awal

Diagnosis menjelaskan mengapa model menghasilkan performa tertentu: kelas yang paling sulit, pola kesalahan, kontribusi kelompok fitur, pengaruh citra aug_noise_*, serta pengaruh perbedaan jenis citra cataract. Analisis utama memakai validation. Metrik test pada Tabel 18 dan Tabel 19 hanya melaporkan kembali prediksi test yang sudah disimpan pada Bagian H dan tidak dipakai untuk mengubah pilihan model.

1. Kinerja per Kelas dan Pasangan Kesalahan

Tabel 18. Precision, recall, dan F1 per kelas (SVM RBF final)

Kelas	Val P	Val R	Val F1	Val n	Test P	Test R	Test F1	Test n
cataract	1,000	1,000	1,000	54	1,000	1,000	1,000	55
diabetic_retinopathy	0,916	0,873	0,894	150	0,860	0,894	0,877	151
glaucoma	0,766	0,742	0,754	132	0,716	0,615	0,661	135
normal	0,705	0,782	0,742	101	0,583	0,657	0,618	102

Tabel 19. Pasangan kesalahan terbanyak (jumlah citra, SVM RBF final)

Kelas aktual	Diprediksi sebagai	Validation	Test
glaucoma	normal	26	43
normal	glaucoma	18	22
diabetic_retinopathy	glaucoma	12	11
glaucoma	diabetic_retinopathy	8	9
diabetic_retinopathy	normal	7	5
normal	diabetic_retinopathy	4	13

Cataract dikenali sempurna (F1 1,000 pada validation dan test), sedangkan glaucoma dan normal paling sulit (F1 test 0,661 dan 0,618). Kesalahan terbanyak adalah glaucoma yang diprediksi normal (26 citra di validation dan 43 di test) dan sebaliknya (18 dan 22), diikuti diabetic_retinopathy yang diprediksi glaucoma (12 dan 11). Hipotesis kami adalah fitur global (warna, tekstur, dan HOG pada citra 64×64) tidak menangkap perubahan cup dan disc optik pada glaukoma. Hipotesis ini belum diuji dan akan diuji pada tahap berikutnya dengan fitur wilayah optic disc.

2. Pengaruh Kelompok Fitur

Pengaruh tiap kelompok fitur diukur dengan permutation importance pada validation: nilai satu kelompok diacak sekaligus (10 pengulangan) dan penurunan Macro F1 model final dicatat (Tabel 20).

Tabel 20. Penurunan Macro F1 ketika satu kelompok fitur diacak (validation)

Kelompok fitur	Jumlah fitur	Penurunan Macro F1 (rata-rata ± std)
HOG	324	0,5157 ± 0,0210
Warna	12	0,1001 ± 0,0165
Tekstur	14	0,0751 ± 0,0128
Ketajaman	6	0,0166 ± 0,0071

HOG paling berpengaruh: pengacakannya menurunkan Macro F1 sebesar 0,5157, jauh di atas warna (0,1001), tekstur (0,0751), dan ketajaman (0,0166). Perbandingan ini sebagian dipengaruhi jumlah fitur per kelompok (324 dibanding 6 sampai 14). Permutation importance mengukur ketergantungan model, bukan hubungan sebab-akibat.

3. Pengaruh Citra aug_noise_*

Macro F1 validation terbaik tiap keluarga model pada dua skenario data latih ditunjukkan pada Tabel 21.

Tabel 21. Macro F1 validation terbaik tiap model, dengan dan tanpa aug_noise_*

Model	Dengan aug_noise_*	Tanpa aug_noise_*	Selisih (dengan - tanpa)
Extra Trees	0,8133	0,8218	-0,0084
LDA	0,8094	0,8188	-0,0094
Passive-Aggressive	0,8100	0,8243	-0,0142
QDA (+PCA)	0,7525	0,7570	-0,0045
Ridge Classifier	0,8097	0,8140	-0,0042
SVM RBF	0,8436	0,8475	-0,0038

Skenario tanpa aug_noise_* lebih baik pada 6 dari 6 keluarga model, dengan selisih kecil (0,004 sampai 0,014) pada satu split validation. Hasil ini merupakan indikasi, bukan bukti.

4. Skor Empat Kelas Dibandingkan Tiga Kelas Fundus

Karena cataract berbeda jenis citra, skor empat kelas dibandingkan dengan skor pada subset validation tiga kelas fundus (383 citra, observasi yang sama) pada Tabel 22.

Tabel 22. Analisis sensitivitas empat kelas dan tiga kelas (validation)

Model dan ruang evaluasi	Jumlah observasi	Macro F1
Model final 4 kelas pada seluruh validation	437	0,8475
Model final 4 kelas pada subset 3 kelas fundus	383	0,7966
Model dilatih ulang sebagai 3 kelas pada subset validation yang sama	383	0,7869

Macro F1 model final turun dari 0,8475 pada seluruh validation menjadi 0,7966 pada subset fundus, dan model yang dilatih ulang sebagai tiga kelas memperoleh 0,7869. Dengan demikian kemampuan membedakan penyakit retina yang lebih realistis berada pada kisaran 0,79 sampai 0,80 di validation, bukan 0,85. Perbandingan ini bersifat diagnostik pada satu split dan bukan bukti kausal; model tiga kelas juga memiliki ruang label dan jumlah data latih yang berbeda.

5. Keterbatasan

1. **Shortcut learning pada kelas cataract (terkonfirmasi).** Cataract berupa foto mata bagian luar, sedangkan tiga kelas lain berupa citra fundus, sehingga model dapat memisahkannya hanya dari jenis citra. Skor empat kelas tidak boleh dibaca sebagai kemampuan mendeteksi penyakit; skor tiga kelas fundus lebih representatif.
2. **Split belum berbasis pasien atau sumber citra.** Citra asli dan turunannya dapat berada pada fold berbeda sehingga CV acak berpotensi optimistik. Tahap berikutnya perlu mengidentifikasi grup sumber dan mempertimbangkan StratifiedGroupKFold.
3. **Audit duplikasi memakai informasi lintas split.** Test tidak dihapus pada tahap near-duplicate, tetapi hash dan kemiripannya dipakai untuk mengeluarkan salinan dari train, sehingga test bukan *blind* pada tahap kurasi [12].
4. **Pemilihan fitur memakai CV training dan pemilihan konfigurasi memakai validation.** CV yang dilaporkan untuk konfigurasi terpilih merupakan indikator

kestabilan, bukan estimasi bebas bias dari seluruh proses seleksi. Nested CV atau group CV dapat ditambahkan pada tahap berikutnya.

5. **Label dan fitur bersifat tingkat dataset.** Label belum diverifikasi oleh tenaga medis dan fitur warna, tekstur, ketajaman, serta HOG bukan representasi klinis yang lengkap. Model ini bukan alat diagnosis.
6. **Pencarian hyperparameter masih terbatas** dan memakai satu split validation untuk membandingkan banyak konfigurasi. Ensemble yang diuji baru hard voting; soft voting, bagging, stacking, kalibrasi, dan analisis error visual menjadi pekerjaan berikutnya.

J. Rencana Tahap Berikutnya

1. Memverifikasi dan status registry, sumber dan modalitas citra tiap kelas, serta mendiskusikan potensi shortcut dengan dosen, agar identitas proyek dan interpretasi masalah tepat.
2. Menelusuri citra asli dan turunan augmentasi, membentuk grup sumber atau keluarga augmentasi bila informasinya tersedia, lalu mengevaluasi dengan StratifiedGroupKFold untuk mengurangi kebocoran antar-fold.
3. Memperluas feature engineering: LBP multi-radius, histogram warna, fitur wilayah optic disc dan pembuluh darah, seleksi fitur, dan PCA di dalam pipeline, lalu menguji pengaruhnya dengan ablation fitur.
4. Melakukan tuning sistematis pada model teratas dengan CV atau nested CV pada data latih untuk mengurangi bias akibat pemilihan konfigurasi pada satu split validation.
5. Membandingkan soft voting, bagging, atau stacking dengan hard voting dan model tunggal terbaik untuk menilai apakah ensemble memberi peningkatan yang konsisten.
6. Melakukan analisis error visual, kalibrasi probabilitas, dan evaluasi recall serta F1 per kelas untuk memahami pola kegagalan dan tingkat kepercayaan prediksi.
7. Mengunci pipeline dan model sebelum evaluasi test final, lalu memfinalkan notebook, repository, laporan, dan presentasi agar dapat direproduksi.
8. Memisahkan evaluasi cataract dari tiga kelas fundus (atau mencari citra fundus untuk cataract), menangani lap_var yang sangat miring (misalnya transformasi logaritma), dan membandingkan ulang Logistic Regression yang dituning dengan SVM, dengan skor tiga kelas fundus sebagai skor utama.

Daftar Pustaka

[1] World Health Organization, “World report on vision,” Geneva: World Health Organization, 2019.
Link : https://www.who.int/publications-detail/world-report-on-vision

[2] U. R. Acharya, C. M. Lim, E. Y. K. Ng, C. Chee, dan T. Tamura, “Computer-based detection of diabetes retinopathy stages using digital fundus images,” Proc. Institution

of Mechanical Engineers, Part H: Journal of Engineering in Medicine, vol. 223, no. 5, pp. 545-553, 2009.
Link : https://pubmed.ncbi.nlm.nih.gov/19623908/

[3] M. D. Abràmoff, M. K. Garvin, dan M. Sonka, "Retinal imaging and image analysis," IEEE Reviews in Biomedical Engineering, vol. 3, pp. 169-208, 2010.
Link : https://pmc.ncbi.nlm.nih.gov/articles/PMC3131209

[4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
Link : https://jmlr.org/papers/v12/pedregosa11a.html

[5] R. Geirhos et al., "Shortcut learning in deep neural networks," Nature Machine Intelligence, vol. 2, pp. 665-673, 2020.
Link : https://doi.org/10.1038/s42256-020-00257-z

[6] mahin661, "Eye Disease Classification – Fundus Image Dataset," Kaggle. [Online]. Tersedia: https://www.kaggle.com/datasets/mahin661/eye-disease-classification-fundus-image-dataset (akses pada: 9 November 2026).

[7] C. Cortes dan V. Vapnik, "Support-vector networks," Machine Learning, vol. 20, no. 3, pp. 273-297, 1995.
Link : https://doi.org/10.1007/BF00994018

[8] T. G. Dietterich, "Ensemble methods in machine learning," dalam Multiple Classifier Systems (MCS 2000), Lecture Notes in Computer Science, vol. 1857, Berlin: Springer, 2000, pp. 1-15.
Link : https://doi.org/10.1007/3-540-45014-9_1

[9] N. Dalal dan B. Triggs, "Histograms of oriented gradients for human detection," dalam Proc. IEEE Computer Society Conf. on Computer Vision and Pattern Recognition (CVPR), vol. 1, 2005, pp. 886-893.
Link : https://doi.org/10.1109/CVPR.2005.177

[10] T. Ojala, M. Pietikäinen, dan T. Mäenpää, "Multiresolution gray-scale and rotation invariant texture classification with local binary patterns," IEEE Trans. Pattern Analysis and Machine Intelligence, vol. 24, no. 7, pp. 971-987, 2002.
Link : https://doi.org/10.1109/TPAMI.2002.1017623

[11] R. M. Haralick, K. Shanmugam, dan I. Dinstein, "Textural features for image classification," IEEE Trans. Systems, Man, and Cybernetics, vol. SMC-3, no. 6, pp. 610-621, 1973.
Link : https://doi.org/10.1109/TSMC.1973.4309314

[12] S. Kaufman, S. Rosset, C. Perlich, dan O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance," ACM Trans. Knowledge Discovery from Data, vol. 6, no. 4, art. 15, 2012.
Link : https://doi.org/10.1145/2382577.2382579

[13] H. He dan E. A. Garcia, "Learning from imbalanced data," IEEE Trans. Knowledge and Data Engineering, vol. 21, no. 9, pp. 1263-1284, 2009.

Link : https://doi.org/10.1109/TKDE.2008.239

[14] Z. Wang, A. C. Bovik, H. R. Sheikh, dan E. P. Simoncelli, “Image quality assessment: From error visibility to structural similarity,” IEEE Trans. Image Processing, vol. 13, no. 4, pp. 600-612, 2004.
Link : https://doi.org/10.1109/TIP.2003.819861

[15] S. van der Walt et al., “scikit-image: image processing in Python,” PeerJ, vol. 2, art. e453, 2014.
Link : https://doi.org/10.7717/peerj.453

[16] R. Kohavi, “A study of cross-validation and bootstrap for accuracy estimation and model selection,” dalam Proc. 14th Int. Joint Conf. on Artificial Intelligence (IJCAI), 1995, pp. 1137-1143.
Link : https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf